Адаптация EL2N (Deep Learning on a Data Diet, NeurIPS 2021) к классификации текста

Курс «Efficient Models» (ИТМО, 2026) · Домашнее задание 2 · Выполнил: Смирнов Василий Артурович

Статья: M. Paul, S. Ganguli, G. K. Dziugaite. *Deep Learning on a Data Diet: Finding Important Examples Early in Training*. NeurIPS 2021 (arXiv:2107.07075). Официальный код: github.com/mansheej/data_diet.

---

1. Суть метода

Статья отвечает на вопрос: *какие примеры обучающей выборки действительно нужны для обобщения и как найти их, не дообучая модель?* Авторы предлагают два «ранних» счёта важности примера, вычисляемых через несколько эпох обычного обучения:

- **GraNd** — L2-норма градиента функции потерь по всем параметрам: $\mathrm{GraNd}(x, y) = \|\nabla_\theta \ell(f_\theta(x), y)\|_2$
- **EL2N** — L2-норма разности вектора вероятностей и one-hot метки:

$\mathrm{EL2N}(x, y) = \|p_\theta(x) - y\|_2$, где $p = \mathrm{softmax}(\mathrm{logits})$, y — one-hot.

Связь между ними: для cross-entropy градиент потерь по логитам ровно равен $(p - y)$. GraNd — это $\|\nabla_\theta \ell\|_2 = \|J^\top (p - y)\|_2$, где J — якобиан логитов по всем параметрам; EL2N берёт норму только самого вектора $(p - y)$. Равенства вида $\|J^\top (p - y)\| = C \cdot \|p - y\|$ с универсальной константой C не существует, поэтому EL2N — не «GraNd с отброшенным множителем», а значительно более дешёвый proxy градиентной важности (один forward вместо обратного прохода); в статье он эмпирически сильно коррелирует с GraNd и не уступает ему в качестве отбора.

Ключевые наблюдения статьи (CIFAR-10/100, CINIC-10, ResNet-18/50 с нуля):

1. Счета считаются **рано** (эпоха 10–20 из 200) и **усредняются по 10 независимым инициализациям** — это убирает специфику весов и оставляет свойство датасета.
2. Отбор — глобальное **keep-top-k**: оставляем примеры с *наибольшим* счётом («трудные» примеры).
3. Переобучение с нуля на подвыборке при **том же числе шагов оптимизатора и том же LR-расписании** — честное сравнение по оптимизационному бюджету.

4. EL2N из 5% обучения позволяет убрать **50% CIFAR-10 без потери точности** (с небольшим выигрышем) и не уступает forgetting score, требующему полной траектории обучения. На экстремальном прунинге (≤25%) точность резко падает из-за плохого покрытия распределения.
5. Ранги переносимы между архитектурами и гиперпараметрами; high-score хвост концентрирует шумные примеры; баланс классов сохраняется.

2. Дизайн репродукции

В данной работе вместо оригинальной постановки CIFAR/ResNet выбрана **NLP-задача классификации текста** — **AG News** (120 000 / 7 600 примеров, 4 сбалансированных класса новостных заголовков) и небольшая transformer-модель **DistilBERT-base** (~66M параметров). Выбор корректен как NLP-аналог CIFAR: та же постановка (многоклассовая классификация сильно избыточного small-data набора сбалансированными классами).

Воспроизводится центральный эксперимент статьи (аналог Fig. 1, bottom row):

> точность тестовой модели vs доля оставленных данных — для отбора по EL2N и для случайного отбора, на фоне обучения на полном датасете.

Совпадение протоколов с оригиналом (проверено по официальному коду):

Свойство протокола	**Статья**	**Репродукция**
Счёт	$\|p - \text{onehot}(y)\|_2$	идентичная формула
Момент счёта	эпоха 10–20 из 200 (~5–10% шагов)	шаг 937 = 1 эпоха из 3 (33% шагов)
Усреднение	10 инициализаций	10 сидов (инициализация головы + порядок данных + dropout)
Отбор	глобальный keep-top-k по среднему	тот же (`argsort()[-k:]`)
Переобучение	новые инициализации, сиды ≠ сидов скоринга	то же (диапазоны сидов 2xxx vs 1xxx)
Оптимизационный бюджет	фикс. 78 000 шагов на все размеры	фикс. 2811 шагов на все размеры
Random-бейзлайн	свой случайный subset на каждый прогон	то же
Прогонов на точку	4	4

Осознанные отличия (NLP-адаптация):

- **Finetune вместо обучения с нуля**: единственный источник «инициализации» — случайность головы/порядка данных/dropout; предобученный backbone одинаков во всех сидах. В статье усреднение убирает вариацию *всех* весов.
- SGD+stepped decay заменён на стандартный для трансформеров AdamW с линейным decay; длина последовательности 128 (покрывает p99 длин AG News).
- **Точка scoring**: поскольку исходный 200-эпохный режим обучения заменён трёхэпохным fine-tuning, scoring выполнялся после первой полной эпохи (шаг 937 = 33% бюджета шагов) вместо 5–10% в оригинальном протоколе. Это **существенное отличие** от оригинального эксперимента. Выбор согласуется с последующей NLP-литературой (см. §5): для fine-tune предобученных моделей счётчики до конца первой эпохи ненадёжны. Дополнительный scoring на 10% бюджета (§5, п.4) дал высокую корреляцию рангов (ρ = 0.898) — наблюдаемые эффекты не объясняются только более поздней точкой scoring.

3. Установка эксперимента

- **Модель:** `distilbert-base-uncased`, классификационная голова Linear(768→4), инициализируется заново на каждом прогоне.
- **Обучение:** AdamW (lr 5e-5, wd 0.01, без decay на bias/norm), batch 128, warmup 5% + линейный decay до 0 за 2811 шагов, grad-clip 1.0, bf16, динамический паддинг; хвостовой неполный батч каждой эпохи отбрасывается (как в официальном коде).
- **Скоринг:** 10 прогонов сидами 1000–1009; на шаге 937 (конец 1-й эпохи полного расписания) считается EL2N по всем 120k обучающих примеров; среднее по 10 сидам даёт ранжирование.
- **Подвыборки:** 10/25/50/75% = 12k/30k/60k/90k примеров (keep-top по среднему EL2N); random — `RandomState(seed).choice` без возврата, свой сид на прогон.
- **Переобучение:** full(100%) / EL2N / random × 4 прогона, все — ровно 2811 шагов; финальная тестовая точность — основная метрика (как в статье), кривые точности сохраняются.
- **Окружение:** 2× RTX 4090, PyTorch 2.14.1+cu126 (CUDA 12.6), Transformers, Python 3.11; всего 36 переобучений + 10 скоринг-ранов, GPU-время ≈ 1.9 ч.
- Корректность протокола закрыта юнит-тестами (`code/tests/test_protocol.py`: формула EL2N, keep-top, фикс-шаговое циклирование подвыборок, LR-расписание, непересекающиеся сиды) — 13 тестов.

4. Результаты

Основная таблица (финальная тестовая точность %, среднее ± станд. откл. по 4 прогонам):

retained	EL2N top-score	random	EL2N − random, п.п.
10%	28.98 ± 0.94	92.12 ± 0.13	-63.14
25%	81.71 ± 0.63	93.10 ± 0.15	-11.39
50%	93.80 ± 0.20	93.69 ± 0.14	+0.10
75%	94.47 ± 0.06	94.22 ± 0.19	+0.25

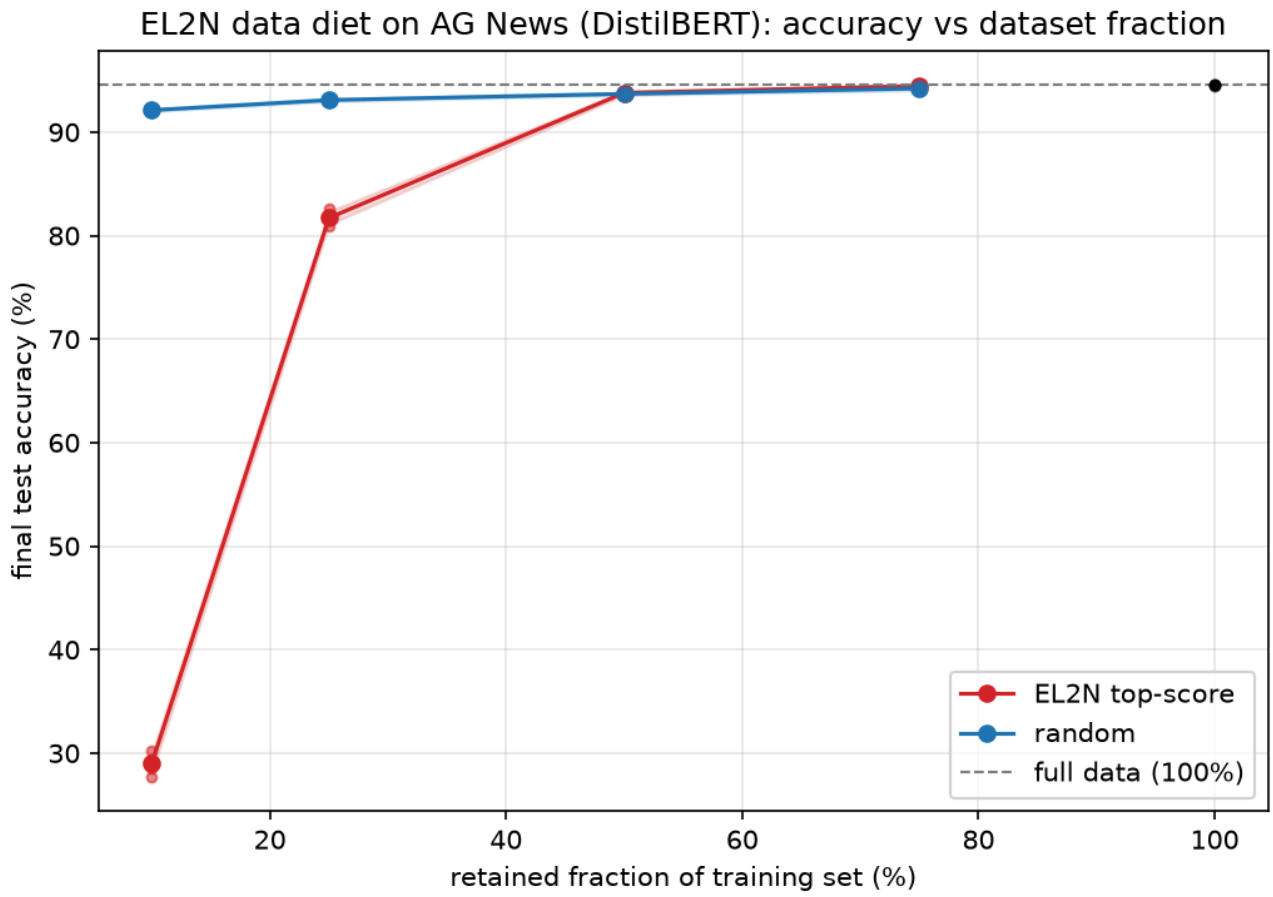
Full dataset (100%): 94.53 ± 0.03 (прогоны: 94.57, 94.54, 94.54, 94.49).

Что видно

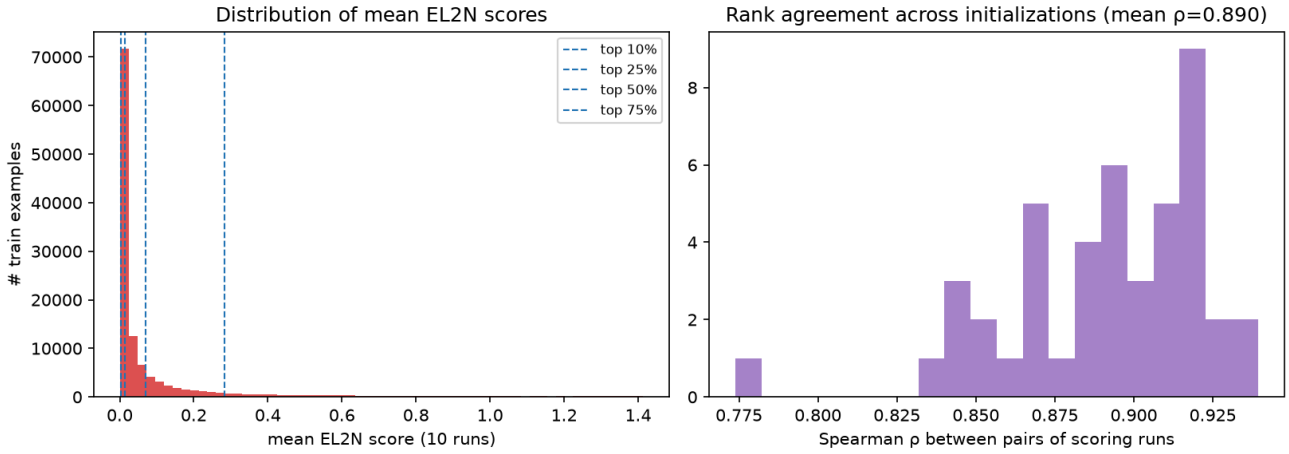
1. **Эффект data diet наблюдается и в NLP-постановке**: даже random-подвыборки размером 10–25% достигают 92.1–93.1% против 94.53 ± 0.03 на полном датасете, а EL2N достигает 93.80 ± 0.20 / 94.47 ± 0.06 при 50–75% данных. Задачу, модель и протокол мы считаем несопоставимыми с CIFAR напрямую, поэтому не утверждаем, что эффект «сильнее», чем в статье; в рамках же этой постановки прирост точности от 10% random-подвыборки до полного датасета составляет всего ≈2.4 п.п. — для достижения близкой к full-data точности достаточно существенно меньшей части AG News.
2. **Устойчивость EL2N как счётчика**: средний Spearman между парами из 10 скоринг-ранов ρ = 0.890 ([0.774, 0.939]) — ранг примеров почти не зависит от инициализации, усреднение по сидам согласовано (аналог наблюдения статьи о переносимости рангов).
3. **В среднем диапазоне (50–75%) заметного преимущества EL2N над random по этим экспериментам не наблюдается** (+0.10 и +0.25 п.п. — в пределах наблюдаемого межпрогонного разброса; формальных статистических тестов не проводилось — по 4 прогона на точку), т.е. выигрыша EL2N, показанного на CIFAR, здесь не видно; а **в малом диапазоне EL2N резко уступает** random (28.98 против 92.12 на 10%; 81.71 против 93.10 на 25%).
4. **Малые EL2N-подвыборки деградируют двумя разными способами** (см. рисунок кривых): на 10% модель **не обучается с самого начала** (≈29% с первого evaluation — в обучающем наборе остаётся лишь 343 примера Sports (2.9%), а доля примеров со счётом > 1 составляет 20.1% против 1.95–2.13% в random-подвыборках того же размера; примеры со счётом > 1 по содержанию часто выглядят как потенциальные несоответствия текста и метки); на 25% модель набирает пик 90.9% к шагу 400, затем **переобучается** с осцилляциями до ~81% финальной точности (2811 шагов = 12+ эпох по 12k/30k примерам при

фиксированном бюджете шагов из протокола статьи). У random-подвыборок переобучение мягче, коллапса покрытия нет.

5. **Классовый баланс EL2N-подсетей НЕ сохранён** (в отличие от Fig. 7 статьи): для 10%-подвыборки доли классов — 22.9%, 2.9%, 35.4%, 38.9%, для 50% — 16.4%, 7.6%, 29.4%, 46.5% (World, Sports, Business, Sci/Tech). Класс Sports почти полностью выпадает из «трудных», тогда как random-подвыборка 10% сохраняет состав 24–26% на класс. Это **согласуется с гипотезой**, что потеря классового покрытия — одна из возможных причин провала на малых размерах (именно такое объяснение — «плохое покрытие распределения» — авторы статьи предлагали для резкого падения точности на CIFAR). Контрольного сравнения с class-balanced EL2N-подвыборкой того же размера мы не проводили, поэтому механизм остаётся правдоподобным, но не изолированным экспериментом.


EL2N data diet on AG News (DistilBERT): accuracy vs dataset fraction
final test accuracy (%)
retained fraction of training set (%)
EL2N top-score
random
full data (100%)


Test accuracy vs fixed step budget (same steps for every subset size)
full 100%
el2n 10%
el2n 50%
random 10%
test accuracy (%)
optimizer step



Качественно: что попадает в high-EL2N

класс	EL2N	пример (обрезан)
World	1.411	Rulon Gardner Wins First Two Matches ATHENS, Greece (AP) -- Rulon Gardner won two pool matches Tuesday, his first in the Olympics since his monumental…
Sports	1.413	Baghdad blasts kills at least 16 Insurgents have detonated two bombs near a convoy of US military vehicles in southern Baghdad, killing at least 16 pe…
Business	1.412	Suicide Bombings Kill 10 in Green Zone Insurgents hand-carried explosives into the most fortified section of Baghdad Thursday and detonated them withi…

В топ счёта попадают примеры со счётом ≈ 1.41 = √2 — это верхняя граница $\|p - y\|_2$ (модель уверенно отдаёт всю вероятность другому классу). В просмотренной нами небольшой выборке таких примеров встречаются случаи, которые семантически выглядят как потенциальное несоответствие текста и метки: сообщения о взрывах в Ираке с метками Sports/Business/Sci-Tech, спортивный текст про олимпийского борца с меткой World. Независимая проверка меток по ground truth не проводилась — это только содержательный просмотр. По характеру феномен напоминает детекцию шума из Fig. 4/Fig. 8 статьи (там — «странные» картинки). Обрывки и лексически редкие примеры дают чуть меньшие, но тоже высокие значения.

5. Сравнение со статьёй

Наблюдение статьи	Наша репродукция
Данные сильно избыточны: 50% ≈ 100%	**Подтверждено и в NLP-постановке**: для random уже 10–25% ≈ 100% (−1.4…−2.4 п.п.); EL2N достигает этого к 50–75%. Прямое численное сравнение с CIFAR некорректно (другие задача, модель, протокол)
EL2N ≥ random в среднем диапазоне	Частично: при 50–75% EL2N формально впереди на +0.1…+0.25 п.п. (в пределах шума), заметного выигрыша нет
На 10% резкое падение точности	Подтверждено: EL2N на 10% не обучается вовсе (29%); наблюдаемые спутники — потеря класса Sports (2.9%) и доля примеров со счётом >1 в 20.1% (против ~2% у random)
Устойчивость рангов между инициализациями	**Подтверждено** (ρ ≈ 0.890)
Баланс классов при keep-top (Fig. 7)	**Не подтверждено**: Sports выпадает из подвыборок (см. §4, п.5)
High-score = шум/ пограничные примеры	В просмотренной небольшой top-выборке встречаются случаи, выглядящие как потенциальное несоответствие текста и метки (ground truth не проверялся)
EL2N при 50% *немного улучшает* full	Не наблюдалось: улучшение есть у обоих методов в пределах ±0.2 п.п.

Вероятные причины отличий — свойства постановки (свидетельств ошибок реализации мы не нашли, корректность протокола закрыта тестами):

1. **Предобученная модель.** В CIFAR-экспериментах сеть учится с нуля и каждый «трудный» пример реально формирует решающую границу. DistilBERT приходит с готовыми языковыми представлениями: «трудность» примера почти не влияет на то, что модель выучит, поэтому, **вероятно**, keep-top не даёт здесь выигрыша — бóльшее значение приобретает **покрытие распределения**, а оно у random-подвыборок лучше уже при 10–25%. Эксперимента, напрямую разделяющего coverage и difficulty (например, size-matched подвыборки, сбалансированные по классам), мы не проводили — это гипотеза.
2. **4 класса и «лёгкая» задача.** Вероятностная ошибка EL2N концентрируется на примерах, уверенно не совпадающих с меткой: во всём AG News доля примеров со средним счётом > 1 составляет 2.0%, в random-подвыборке 10% — 1.95–2.13% (случайная выборка сохраняет фоновую долю), а в EL2N-подвыборке 10% keep-top доводит её до 20.1%.
3. **Фиксированный бюджет шагов** (протокол статьи) для 3-эпохного трансформерного рецепта означает 12–30 эпох на 10–25%-подвыборках — переобучение на 25%; в статье с 200-эпохным full-расписанием и strong-augmentation этот эффект был слабее.

4. Счёт на 33% бюджета шагов вместо 5–10% — более «поздний», чем в статье. Мы это проверили отдельно: сняли EL2N раньше (шаг 281 = 10% расписания, 3 сида) — ранги почти совпадают с основным снапшотом (ρ = 0.898), а класс-перекос сохраняется (Sports в top-10%: 5.4% на шаге 281 против 2.9% на шаге 937). То есть перекос наблюдается и при более ранней точке scoring и не выглядит артефактом выбора шага 937: в данной постановке Sports оказывается существенно менее представлен среди high-EL2N примеров на обоих проверенных чекпойнтах. Возможное объяснение — текстовая однотипность новостей этого класса (они раньше становятся «лёгкими»), однако она отдельно не проверялась; за пределами двух измеренных чекпойнтов мы ничего не утверждаем.

Отдельно отметим, что перенос градиентных счётчиков (GraNd/EL2N) на NLP ранее исследовался в работе *BERT on a Data Diet: Finding Important Examples by Gradient-Based Pruning* (Fayyaz et al., 2022, arXiv:2211.05610) — авторы применяют эти метрики к fine-tuning BERT и показывают, что в NLP они «need to be computed after at least one epoch of fine-tuning and they are not reliable in early steps». Поэтому выбор конца первой эпохи как точки scoring в данной работе согласуется с последующей NLP-литературой (хотя модель, задача и результаты той работы у нас не воспроизводились).

6. Выводы

- Основные этапы протокола EL2N из статьи были перенесены на NLP-задачу: ранний scoring → усреднение по 10 инициализациям → global keep-top-k → переобучение на подвыборках при фиксированном бюджете шагов → сравнение с random и full. Это **адаптация алгоритмического протокола**, а не буквальное воспроизведение оригинального эксперимента: изменены архитектура, режим обучения (finetune вместо обучения с нуля), оптимизатор и относительная точка scoring (5–10% → 33%).
- Эффект data diet наблюдается и в NLP-постановке: уже 10–25% AG News дают 92–93% против 94.5% на полном датасете; 75% EL2N дают 94.47% — в пределах наблюдаемого разброса от full (94.53%).
- Преимущество EL2N над random, наблюдаемое в исходной работе, в данной NLP-постановке **не проявилось**: при 50–75% разница лежит в пределах наблюдаемого межпрогонного разброса, а при 10–25% EL2N существенно хуже (наблюдаемые спутники деградации — потеря классового покрытия и высокая доля примеров со счётом > 1; изоляция механизмов контрольным экспериментом не проводилась). Сравнение с forgetting score в данной работе не воспроизводилось.
- Отчёт зафиксировал все отклонения от статьи без подгонки.

Приложение A. Как воспроизвести

```
 python -m el2n_nlp.cli tokenize   # токен кэш (~1 мин)
python code/orchestrate.py        # 10 скоринг -> отбор -> 36 переобучений (~1 ч на 2
python -m el2n_nlp.cli collect    # таблица + графики
python -m el2n_nlp.cli examples   # качественные примеры
python code/make_report.py && python code/make_slides.py
```

Приложение B. Сводка по прогонам

Каждый прогон — `results/runs/<mode>_<pct>pct_run<k>.json`: сид, размер подвыборки, история `(step, test_acc, test_loss)`, время. Средние — `results/summary.json`; таблицы — `results/table.md`; ранжирование — `results/subsets/el2n_mean_scores.npy`.