EFFICIENT MODELS 2026 · ДОМАШНЕЕ ЗАДАНИЕ 2 · ПЕРЕНОС ПРОТОКОЛА В NLP

Deep Learning on a Data Diet: Finding Important Examples Early in Training

Mansheej Paul, Surya Ganguli, Gintare Karolina Dziugaite — **NeurIPS 2021**

Адаптация EL2N к NLP: AG News + DistilBERT · Смирнов Василий Артурович

ПОСТАНОВКА

Сколько данных — лишние?

- Сети переобучены по параметрам, датасеты — по объёму: значительная часть примеров **не нужна для обобщения**.
- Вопрос работы: **какие** примеры важны и **как найти их рано**, не обучая модель до конца?
- Зачем: меньше памяти и шагов обучения, дешевле HPO, меньше поверхность для атак и ошибок, виден «скелет» данных.
- Аналогия: данные на «диете» — если 50% примеров можно выкинуть **без потери качества**, тестовая точность — та же, а стоимость — вдвое меньше.

КОНТЕКСТ

Что было до статьи

Forgetting events (Toneva et al. 2019)

Пример «забыт» на эпохе t, если на t−1 был верен, а на t — нет. Важные — никогда не забытые. **Минус:** нужен полный прогон обучения — счётчик глобальный и «поздний».

Deep Batch / moderate coreset

Отбор по градиентам на инициализации или по средней трудности за много прогонов. **Минус:** градиенты по всем параметрам дороги; на инициализации сигнал слаб.

Идея статьи: **локальная информация раннего обучения** — простые нормы ошибки/градиента, усреднённые по нескольким инициализациям, — уже через несколько эпох ранжируют данные не хуже поздних метрик.

МЕТОД

Два early-training счёта

GraNd — L2-норма градиента лосса по всем параметрам:

$$\mathrm{GraNd}(x,y) = \|\nabla_\theta\, \ell(f_\theta(x),\, y)\|_2$$

EL2N — L2-норма ошибки между вероятностями и one-hot меткой:

$$\mathrm{EL2N}(x,y) = \|p_\theta(x) - y\|_2$$

Для кросс-энтропии градиент лосса по логитам — в точности **(p − y)**; EL2N — норма только градиента по логитам (для CE это p−y), GraNd — норма всего $\mathbf{J^T(p-y)}$ по параметрам. Это не «GraNd без множителя» (равенства с общей константой нет), а значительно более дешёвый **proxy** градиентной важности: один forward вместо backprop.

МЕТОД

Как устроен протокол отбора

- **1. Parent run:** обычная тренировка; счётчики считаются *рано* (CIFAR-10: эпоха 10 из 200).
- **2. Усреднение:** счётчики складываются по **10 независимым инициализациям** — убирает спецификацию весов, оставляет свойство датасета.
- **3. Отбор:** глобально **keep-top-k** по среднему счёту (оставляем «трудные» примеры!).
- **4. Переобучение с нуля** на подвыборке при *том же числе шагов и расписании LR* (390·200 для CIFAR-10) — сравнение честное по оптимизационному бюджету.
- **5. Отчёт:** 4 независимых прогона на точку; бейзлайны — полный датасет и *random subsets того же размера* (свой subset на прогон).

РЕЗУЛЬТАТЫ СТАТЬИ

Главная табличка

- CIFAR-10 / ResNet-18: EL2N из эпохи 10–20 позволяет убрать **50% обучения и даже slightly улучшить** тестовую точность (~95.1% → ~95.3%).
- EL2N, посчитанный **на 5% обучения**, сопоставим с forgetting score, посчитанным **после 100%** обучения.
- GraNd **на инициализации** — почти не работает (исправление ошибки ранней версии статьи).
- При экстремальном прунинге (≤10–25%) — резкое падение: top-score примеры плохо покрывают распределение.

РЕЗУЛЬТАТЫ СТАТЬИ

Свойства счётов

- **Ранг устойчив:** EL2N на эпохе 10 коррелирует с forgetting на финале ($\rho \approx 0.75$–0.8); счётчики на разных эпохах согласованы.
- **Это свойство данных, а не модели:** ранги переносятся между ResNet-18/50 и между гиперпараметрами (в т.ч. внутри HPO-ранов).
- **Усреднение по инициализациям важно:** счёт одного рана заметно хуже, чем среднее по 10–20 ранам.
- **Шум:** случайно перемаркированные примеры концентрируются в high-EL2N хвосте; top-EL2N CIFAR-примеры — визуально «странные»/пограничные.
- **Классы сбалансированы:** keep-top не ломает баланс классов датасета.

ВЫВОДЫ СТАТЬИ

Значение

- Важность примера — **локальное, ранее** свойство: не нужна полная траектория обучения.
- EL2N дёшев (один forward), переносим между архитектурами — scores можно посчитать один раз и экономить на всех будущих тренировках и HPO.
- Побочные применения: детекция шумных меток, анализ динамики обучения (устойчивые подпространства представлений, форма loss surface).

НАШ ЭКСПЕРИМЕНТ · ПОСТАНОВКА

Перенос эксперимента в NLP

СТАТЬЯ (vision)

CIFAR-10, 50k train / 10 классов
ResNet-18 с нуля
SGD lr=0.1, 200 эп. = 78 000 шагов
EL2N на эпохе 10 из 200
10 инициализаций → mean → keep-top-k
4 рана на точку, 16–84 перцентили

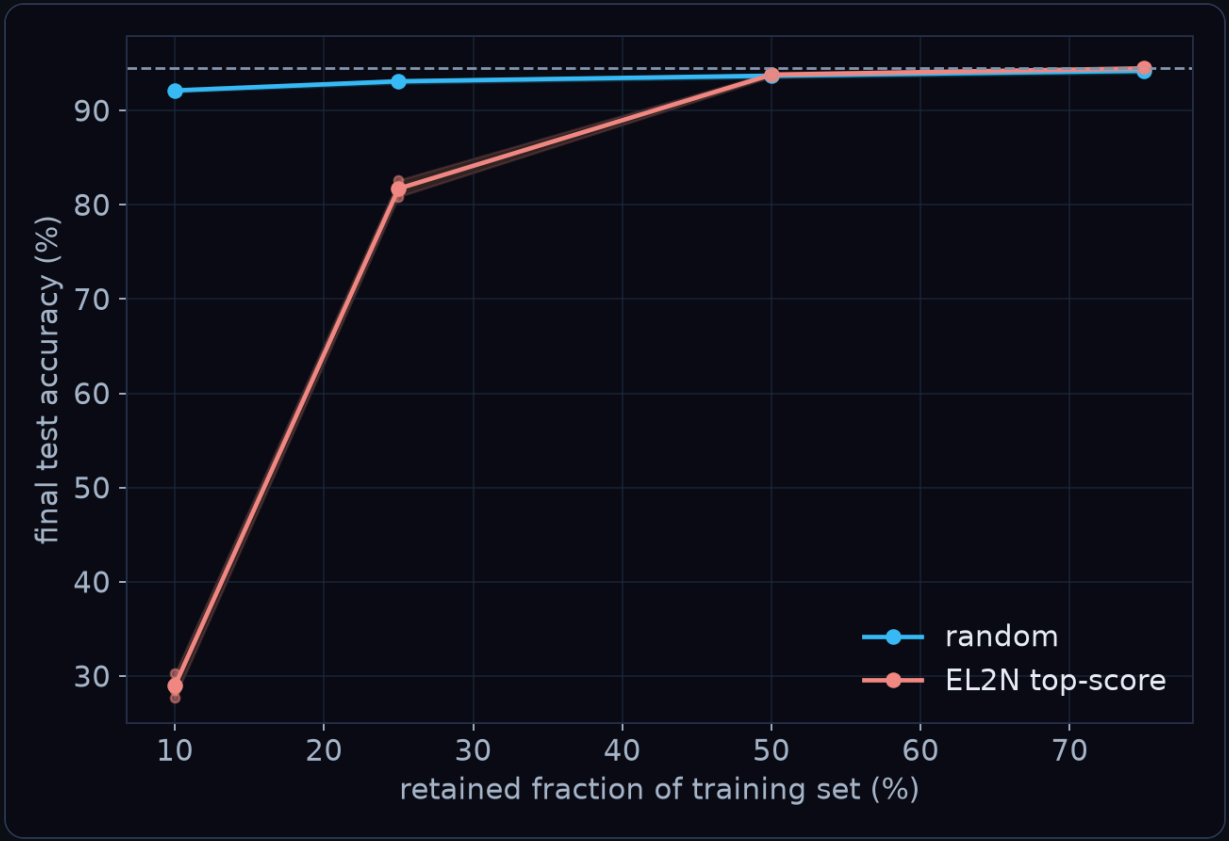
МЫ (NLP)

AG News, 120k train / 4 класса
DistilBERT (finetune, head заново)
AdamW lr=5e-5, 3 эп. = **2811 шагов (фикс)**
EL2N после 1-й эпохи полного расписания
10 сидов → mean → keep-top-k
4 рана на точку (мин/макс на графике)

Ключевые протокольные свойства сохранены: ранний счётчик, усреднение по инициализациям, keep-top, **фиксированное число шагов для всех размеров подвыборки**, отдельные сиды скоринга и обучения, random-бейзлайн.

НАШ ЭКСПЕРИМЕНТ · РЕЗУЛЬТАТЫ

Точность vs размер датасета (AG News, DistilBERT)



% ДАННЫХ	EL2N TOP (ACC %)	RANDOM (ACC %)	EL2N−RAND
10%	28.98 ± 0.94	92.12 ± 0.13	-63.14
25%	81.71 ± 0.63	93.10 ± 0.15	-11.39
50%	93.80 ± 0.20	93.69 ± 0.14	+0.10
75%	94.47 ± 0.06	94.22 ± 0.19	+0.25

Full 100%: **94.53 ± 0.03**

НАШ ЭКСПЕРИМЕНТ · ДИНАМИКА

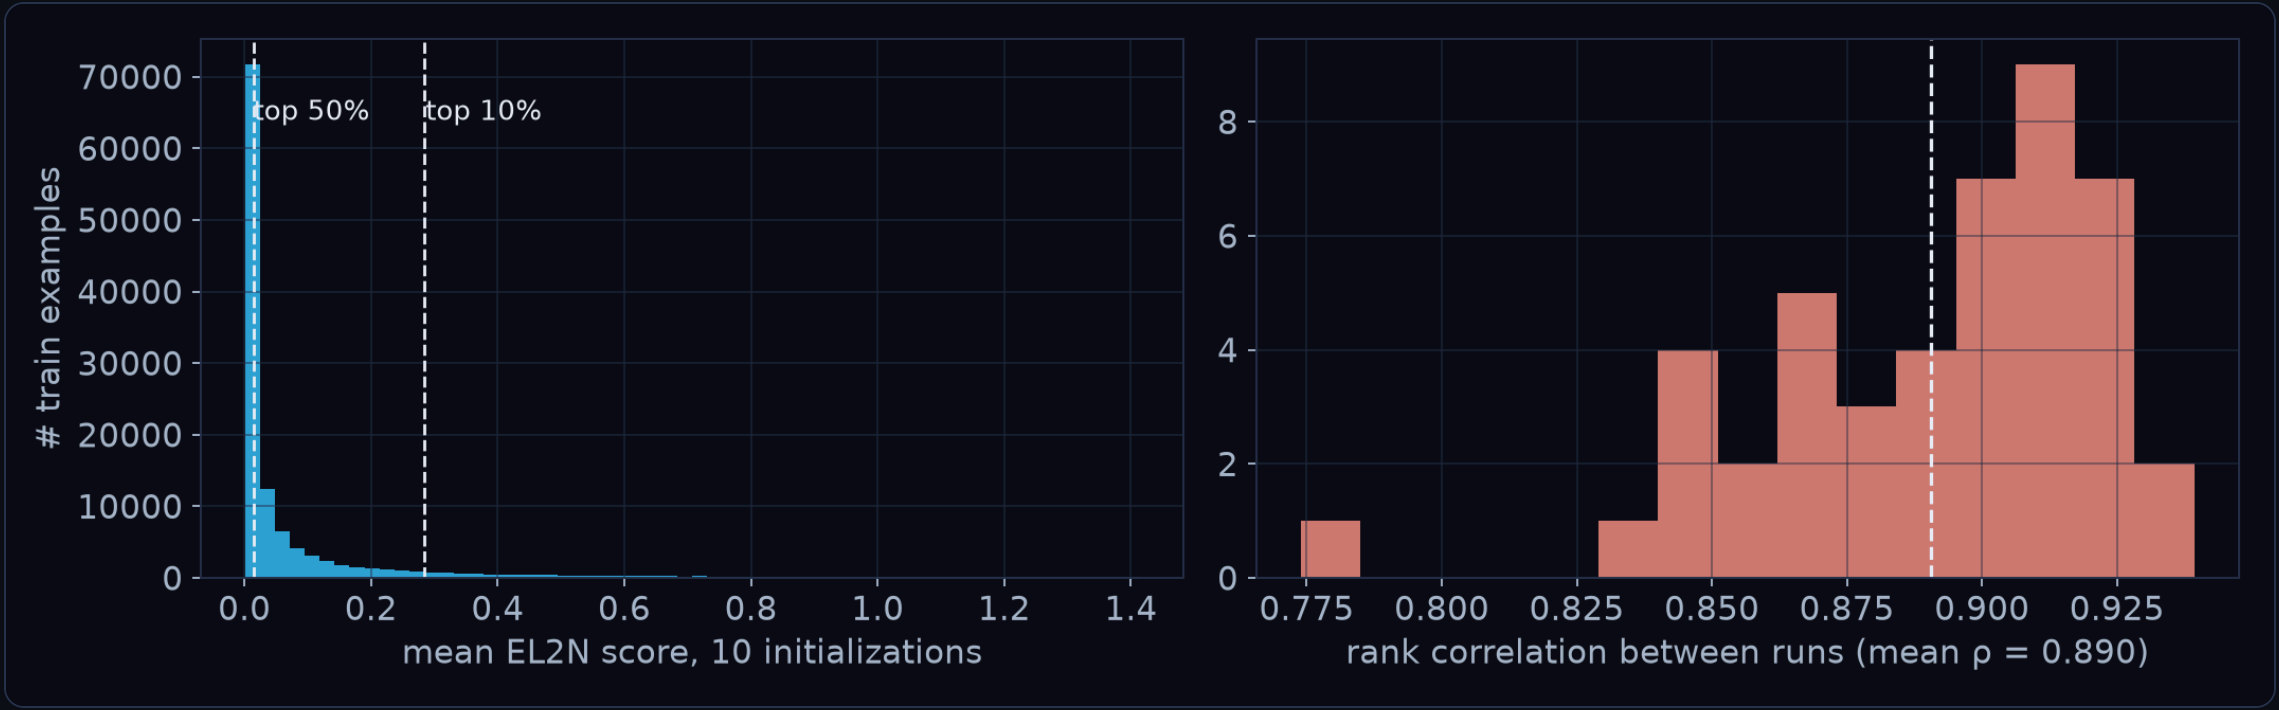
Малые EL2N-подвыборки: два режима отказа



Один и тот же бюджет 2811 шагов (протокол статьи). **EL2N @ 10%** — не обучается вовсе (~29% с первого evaluation): в подвыборке 2.9% Sports (против 25% в датасете) и 20.1% примеров со счётом > 1 (у random ~2%). **EL2N @ 25%** — пик 90.9% к шагу 400, затем переобучение с осцилляциями до ~81%. **Random @ 10%** — ровные ~92% без отказа.

НАШ ЭКСПЕРИМЕНТ · СЧЁТЧИКИ

EL2N-распределение и согласованность инициализаций



Средний Spearman между 10 сидами скоринга: **ρ = 0.890** — ранг примеров устойчив между инициализациями, усреднение по сидам действительно имеет смысл (как в статье).

НАШ ЭКСПЕРИМЕНТ · ЧТО ВНУТРИ TOP-SCORE

Высокий EL2N: по содержанию — шум и пограничные примеры

> «Rulon Gardner Wins First Two Matches ATHENS, Greece (AP) -- Rulon Gardner won two pool matches Tuesday, his first in the Olympics since his monumental gold-medal upset of Russia's …» (World, EL2N=1.411)

> «Dozens killed in Baghdad car bomb More than twenty five people have died after a car bomb exploded in a busy commercial area outside a restaurant in west Baghdad. Husayn al-Shammar…» (Sci/Tech, EL2N=1.412)

- Счёт в топе ≈ 1.41 = **$\sqrt{2}$ — максимум $\|p-y\|_2$**: модель уверенно указывает на другой класс. В просмотренной небольшой выборке такие примеры семантически выглядят как **потенциально ошибочные метки** (взрывы в Багдаде с меткой Sports/Business/Sci-Tech); ground truth независимо не проверялся.
- По характеру — аналог детекции шума из Fig. 4/8 статьи (там — «странные» картинки).
- Отличие от статьи (Fig. 7): классы в подсетях **не** сбалансированы — в top-10% всего 2.9% Sports; согласуется с гипотезой о потере классового покрытия (контрольным опытом не изолировано).

НАШ ЭКСПЕРИМЕНТ · СРАВНЕНИЕ СО СТАТЬЁЙ

Что подтвердилось, что отличается

ПОДТВЕРЖДЕНО

- EL2N считается дёшево и устойчиво (ρ между сидами).
- Половина датасета ≈ полный датасет (и для EL2N, и для random).
- High-score выглядит как шум разметки / пограничные примеры (как Fig. 4/8; просмотр top-выборки).

ОТЛИЧИЕ

- **Заметного преимущества EL2N над random не наблюдается** (+0.10/+0.25 п.п. при 4 прогонах на точку): на finetune трансформера, вероятно, выигрывает «покрытие», а не «трудность».
- На 10% EL2N **не обучается вовсе** (~28%): keep-top теряет класс Sports (2.9%), доля примеров со счётом >1 — 20% против ~2% у random. Согласуется с потерей классового покрытия — механизма контрольным опытом мы не изолировали.

Вероятные причины: предобученная модель вместо с нуля; крошечное число классов и «лёгкая» задача (все 90%+ точности достигаются на любой репрезентативной половине); фиксированный шаг из статьи здесь дорого стоит малым подвыборкам.

ИТОГ

Выводы

- Основные этапы протокола EL2N (Paul et al. 2021) перенесены из vision в NLP: 10 early-ранов → mean-score → keep-top-k → retrain с фикс-шагами (адаптация протокола, не буквальное воспроизведение).
- На AG News + DistilBERT: **random 10% сохраняет 92.12% при 94.53% на full; EL2N 10% — 28.98%**; при 75% EL2N ≈ full (94.47 vs 94.53).
- Преимущество EL2N над random, показанное на CIFAR, **не переносится** в NLP finetuning: при 50–75% — паритет (±0.25 п.п.), при 10–25% EL2N проигрывает; наблюдаемые спутники — потеря класса Sports и доля примеров со счётом >1 в 20%.
- Точка scoring (конец 1-й эпохи) согласуется с *BERT on a Data Diet* (2022): в NLP градиентные счётчики надёжны только после ≥1 эпохи fine-tune.
- Репозиторий: код (воспроизводимый конвейер из 46 прогонов), отчёт (report/), презентация (Презентация.pdf).